

Análisis y modelado del riesgo de impago en tarjetas de crédito

Gabriel Costa Riesco

13/06/2026

Contents

Resumen ejecutivo	2
Contexto y objetivos	2
Metodología	3
Fuente de datos	3
Carga y preparación	3
Lectura de los datos	3
Limpieza de categorías	6
Transformación y nombres descriptivos	7
Diccionario resumido	8
Análisis exploratorio	9
Distribución de la variable objetivo	9
Perfil demográfico	10
Crédito, deuda y pagos	14
Correlaciones	20
Reducción de dimensionalidad con PCA	22
Segmentación no supervisada	25
Selección del número de clústeres	25
K-means con datos originales y normalizados	27
K-medians y PAM	29
Agrupación con distancia Manhattan	32
DBSCAN y OPTICS	33

Modelos supervisados	38
Preparación de entrenamiento y test	38
Árbol de decisión sin poda y podado	39
Random Forest con muestreo balanceado	44
Comparación de modelos	46
Limitaciones y riesgos de uso	47
Conclusiones	48
Referencias	48
Información de la sesión	48
Proyecto de minería de datos	
Segmentación de clientes y predicción del riesgo de impago	
Gabriel Costa Riesco	

Resumen ejecutivo

El objetivo de este proyecto es estudiar el riesgo de impago de clientes con tarjeta de crédito. El análisis combina dos líneas de trabajo:

1. **Segmentación no supervisada**, para identificar perfiles de clientes a partir de su deuda mensual y de los pagos realizados.
2. **Clasificación supervisada**, para estimar si un cliente incurrirá en impago durante el siguiente periodo.

El proyecto cubre el proceso completo: comprensión del problema, preparación del dataset, análisis exploratorio, reducción de dimensionalidad, clustering, entrenamiento de modelos predictivos y evaluación de resultados.

Contexto y objetivos

El impago de una tarjeta de crédito genera pérdidas directas, aumenta los costes de recobro y complica la asignación de nuevos límites de crédito. La finalidad del análisis es aportar una base cuantitativa para:

- detectar grupos de clientes con comportamientos financieros similares;
- estudiar la relación entre deuda, pagos, retrasos y características demográficas;
- construir un modelo que ayude a identificar clientes con mayor riesgo;
- explicar las limitaciones que deben tenerse en cuenta antes de utilizar el modelo en un entorno real.

La variable objetivo es **Pago**. En la fuente original toma el valor 1 cuando se produce un impago en el mes siguiente y 0 cuando no se produce.

Metodología

La estructura del proyecto sigue **CRISP-DM**:

1. **Comprensión del negocio**: reducir la incertidumbre asociada a la concesión y gestión del crédito.
2. **Comprensión de los datos**: revisar variables, distribuciones, valores ausentes y categorías no documentadas.
3. **Preparación**: limpiar categorías, transformar tipos y renombrar variables para facilitar su interpretación.
4. **Modelado**: aplicar PCA, k-means, k-medians, PAM, una variante con distancia Manhattan, DBSCAN, OPTICS, árboles de decisión y Random Forest.
5. **Evaluación**: comparar cohesión de clústeres y métricas de clasificación.
6. **Aplicación**: traducir los resultados a perfiles de riesgo, manteniendo siempre supervisión humana.

Fuente de datos

Se utiliza el dataset Default of Credit Card Clients, publicado en el UCI Machine Learning Repository.

El conjunto contiene 30.000 clientes de una entidad financiera de Taiwán y 25 variables relacionadas con:

- límite de crédito;
- sexo, educación, estado civil y edad;
- retrasos mensuales;
- deuda facturada durante seis meses;
- pagos realizados durante seis meses;
- impago en el siguiente periodo.

El dataset permite aplicar técnicas supervisadas y no supervisadas. Su tamaño es suficiente para separar entrenamiento y test, aunque su antigüedad y su contexto geográfico limitan la generalización de las conclusiones.

Carga y preparación

Lectura de los datos

```
data_path <- file.path("data", "creditcard.xls")

if (!file.exists(data_path)) {
  stop("No se encuentra el archivo data/creditcard.xls")
}

clientes_raw <- readxl::read_excel(
  data_path,
  skip = 1,
  col_names = TRUE
)

dim(clientes_raw)
```

```
## [1] 30000    25
```

```
head(clientes_raw)
```

```
## # A tibble: 6 x 25
##       ID LIMIT_BAL SEX EDUCATION MARRIAGE AGE PAY_0 PAY_2 PAY_3 PAY_4 PAY_5
##   <dbl>   <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1     1    20000     2       2       1    24     2     2    -1    -1    -2
## 2     2   120000     2       2       2    26    -1     2     0     0     0
## 3     3    90000     2       2       2    34     0     0     0     0     0
## 4     4    50000     2       2       1    37     0     0     0     0     0
## 5     5    50000     1       2       1    57    -1     0    -1     0     0
## 6     6    50000     1       1       2    37     0     0     0     0     0
## # i 14 more variables: PAY_6 <dbl>, BILL_AMT1 <dbl>, BILL_AMT2 <dbl>,
## #   BILL_AMT3 <dbl>, BILL_AMT4 <dbl>, BILL_AMT5 <dbl>, BILL_AMT6 <dbl>,
## #   PAY_AMT1 <dbl>, PAY_AMT2 <dbl>, PAY_AMT3 <dbl>, PAY_AMT4 <dbl>,
## #   PAY_AMT5 <dbl>, PAY_AMT6 <dbl>, 'default payment next month' <dbl>
```

El archivo original contiene 30.000 observaciones y 25 columnas. La primera revisión permite comprobar los nombres, tipos y rangos disponibles.

```
str(clientes_raw)
```

```
## tibble [30,000 x 25] (S3: tbl_df/tbl/data.frame)
##  $ ID                : num [1:30000] 1 2 3 4 5 6 7 8 9 10 ...
##  $ LIMIT_BAL         : num [1:30000] 20000 120000 90000 50000 50000 50000 50000 100000 140000 ...
##  $ SEX               : num [1:30000] 2 2 2 2 1 1 1 2 2 1 ...
##  $ EDUCATION         : num [1:30000] 2 2 2 2 2 1 1 2 3 3 ...
##  $ MARRIAGE          : num [1:30000] 1 2 2 1 1 2 2 2 1 2 ...
##  $ AGE               : num [1:30000] 24 26 34 37 57 37 29 23 28 35 ...
##  $ PAY_0             : num [1:30000] 2 -1 0 0 -1 0 0 0 0 -2 ...
##  $ PAY_2             : num [1:30000] 2 2 0 0 0 0 0 -1 0 -2 ...
##  $ PAY_3             : num [1:30000] -1 0 0 0 -1 0 0 -1 2 -2 ...
##  $ PAY_4             : num [1:30000] -1 0 0 0 0 0 0 0 0 -2 ...
##  $ PAY_5             : num [1:30000] -2 0 0 0 0 0 0 0 0 -1 ...
##  $ PAY_6             : num [1:30000] -2 2 0 0 0 0 0 -1 0 -1 ...
##  $ BILL_AMT1         : num [1:30000] 3913 2682 29239 46990 8617 ...
##  $ BILL_AMT2         : num [1:30000] 3102 1725 14027 48233 5670 ...
##  $ BILL_AMT3         : num [1:30000] 689 2682 13559 49291 35835 ...
##  $ BILL_AMT4         : num [1:30000] 0 3272 14331 28314 20940 ...
##  $ BILL_AMT5         : num [1:30000] 0 3455 14948 28959 19146 ...
##  $ BILL_AMT6         : num [1:30000] 0 3261 15549 29547 19131 ...
##  $ PAY_AMT1          : num [1:30000] 0 0 1518 2000 2000 ...
##  $ PAY_AMT2          : num [1:30000] 689 1000 1500 2019 36681 ...
##  $ PAY_AMT3          : num [1:30000] 0 1000 1000 1200 10000 657 38000 0 432 0 ...
##  $ PAY_AMT4          : num [1:30000] 0 1000 1000 1100 9000 ...
##  $ PAY_AMT5          : num [1:30000] 0 0 1000 1069 689 ...
##  $ PAY_AMT6          : num [1:30000] 0 2000 5000 1000 679 ...
##  $ default payment next month: num [1:30000] 1 1 0 0 0 0 0 0 0 0 ...
```

```
summary(clientes_raw)
```

```

##          ID          LIMIT_BAL          SEX          EDUCATION
## Min.      : 1    Min.      : 10000    Min.      :1.000    Min.      :0.000
## 1st Qu.: 7501    1st Qu.: 50000    1st Qu.:1.000    1st Qu.:1.000
## Median :15000    Median : 140000    Median :2.000    Median :2.000
## Mean      :15000    Mean      : 167484    Mean      :1.604    Mean      :1.853
## 3rd Qu.:22500    3rd Qu.: 240000    3rd Qu.:2.000    3rd Qu.:2.000
## Max.      :30000    Max.      :1000000    Max.      :2.000    Max.      :6.000
##      MARRIAGE          AGE          PAY_0          PAY_2
## Min.      :0.000    Min.      :21.00    Min.      : -2.0000    Min.      : -2.0000
## 1st Qu.:1.000    1st Qu.:28.00    1st Qu.: -1.0000    1st Qu.: -1.0000
## Median :2.000    Median :34.00    Median : 0.0000    Median : 0.0000
## Mean      :1.552    Mean      :35.49    Mean      : -0.0167    Mean      : -0.1338
## 3rd Qu.:2.000    3rd Qu.:41.00    3rd Qu.: 0.0000    3rd Qu.: 0.0000
## Max.      :3.000    Max.      :79.00    Max.      : 8.0000    Max.      : 8.0000
##      PAY_3          PAY_4          PAY_5          PAY_6
## Min.      : -2.0000    Min.      : -2.0000    Min.      : -2.0000    Min.      : -2.0000
## 1st Qu.: -1.0000    1st Qu.: -1.0000    1st Qu.: -1.0000    1st Qu.: -1.0000
## Median : 0.0000    Median : 0.0000    Median : 0.0000    Median : 0.0000
## Mean      : -0.1662    Mean      : -0.2207    Mean      : -0.2662    Mean      : -0.2911
## 3rd Qu.: 0.0000    3rd Qu.: 0.0000    3rd Qu.: 0.0000    3rd Qu.: 0.0000
## Max.      : 8.0000    Max.      : 8.0000    Max.      : 8.0000    Max.      : 8.0000
##      BILL_AMT1          BILL_AMT2          BILL_AMT3          BILL_AMT4
## Min.      : -165580    Min.      : -69777    Min.      : -157264    Min.      : -170000
## 1st Qu.: 3559    1st Qu.: 2985    1st Qu.: 2666    1st Qu.: 2327
## Median : 22382    Median : 21200    Median : 20089    Median : 19052
## Mean      : 51223    Mean      : 49179    Mean      : 47013    Mean      : 43263
## 3rd Qu.: 67091    3rd Qu.: 64006    3rd Qu.: 60165    3rd Qu.: 54506
## Max.      : 964511    Max.      : 983931    Max.      :1664089    Max.      : 891586
##      BILL_AMT5          BILL_AMT6          PAY_AMT1          PAY_AMT2
## Min.      : -81334    Min.      : -339603    Min.      : 0    Min.      : 0
## 1st Qu.: 1763    1st Qu.: 1256    1st Qu.: 1000    1st Qu.: 833
## Median : 18105    Median : 17071    Median : 2100    Median : 2009
## Mean      : 40311    Mean      : 38872    Mean      : 5664    Mean      : 5921
## 3rd Qu.: 50191    3rd Qu.: 49198    3rd Qu.: 5006    3rd Qu.: 5000
## Max.      : 927171    Max.      : 961664    Max.      : 873552    Max.      :1684259
##      PAY_AMT3          PAY_AMT4          PAY_AMT5          PAY_AMT6
## Min.      : 0    Min.      : 0    Min.      : 0.0    Min.      : 0.0
## 1st Qu.: 390    1st Qu.: 296    1st Qu.: 252.5    1st Qu.: 117.8
## Median : 1800    Median : 1500    Median : 1500.0    Median : 1500.0
## Mean      : 5226    Mean      : 4826    Mean      : 4799.4    Mean      : 5215.5
## 3rd Qu.: 4505    3rd Qu.: 4013    3rd Qu.: 4031.5    3rd Qu.: 4000.0
## Max.      : 896040    Max.      : 621000    Max.      : 426529.0    Max.      : 528666.0
## default payment next month
## Min.      :0.0000
## 1st Qu.:0.0000
## Median :0.0000
## Mean      :0.2212
## 3rd Qu.:0.0000
## Max.      :1.0000

```

```
colSums(is.na(clientes_raw))
```

```

##          ID          LIMIT_BAL
##          0          0

```

```
##          SEX          EDUCATION
##          0          0
##      MARRIAGE          AGE
##          0          0
##          PAY_0          PAY_2
##          0          0
##          PAY_3          PAY_4
##          0          0
##          PAY_5          PAY_6
##          0          0
##      BILL_AMT1      BILL_AMT2
##          0          0
##      BILL_AMT3      BILL_AMT4
##          0          0
##      BILL_AMT5      BILL_AMT6
##          0          0
##      PAY_AMT1      PAY_AMT2
##          0          0
##      PAY_AMT3      PAY_AMT4
##          0          0
##      PAY_AMT5      PAY_AMT6
##          0          0
## default payment next month
##          0
```

Limpieza de categorías

La documentación define cuatro categorías de educación y tres de estado civil. Los códigos fuera de esos rangos no tienen una interpretación clara, por lo que se eliminan antes del modelado.

```
clientes <- clientes_raw |>
  dplyr::filter(
    EDUCATION %in% c(1, 2, 3, 4),
    MARRIAGE %in% c(1, 2, 3)
  )

filas_eliminadas <- nrow(clientes_raw) - nrow(clientes)
porcentaje_eliminado <- 100 * filas_eliminadas / nrow(clientes_raw)

data.frame(
  filas_originales = nrow(clientes_raw),
  filas_finales = nrow(clientes),
  filas_eliminadas = filas_eliminadas,
  porcentaje_eliminado = round(porcentaje_eliminado, 3)
)
```

```
##      filas_originales filas_finales filas_eliminadas porcentaje_eliminado
## 1          30000          29601          399          1.33
```

La pérdida de observaciones es muy reducida y mejora la interpretabilidad de las variables categóricas.

Transformación y nombres descriptivos

```
rename_map <- c(
  "default payment next month" = "Pago",
  "PAY_0" = "RETRASOS_Septiembre",
  "PAY_2" = "RETRASOS_Agosto",
  "PAY_3" = "RETRASOS_Julio",
  "PAY_4" = "RETRASOS_Junio",
  "PAY_5" = "RETRASOS_Mayo",
  "PAY_6" = "RETRASOS_Abril",
  "BILL_AMT1" = "DEUDA_Septiembre",
  "BILL_AMT2" = "DEUDA_Agosto",
  "BILL_AMT3" = "DEUDA_Julio",
  "BILL_AMT4" = "DEUDA_Junio",
  "BILL_AMT5" = "DEUDA_Mayo",
  "BILL_AMT6" = "DEUDA_Abril",
  "PAY_AMT1" = "PAGADO_Septiembre",
  "PAY_AMT2" = "PAGADO_Agosto",
  "PAY_AMT3" = "PAGADO_Julio",
  "PAY_AMT4" = "PAGADO_Junio",
  "PAY_AMT5" = "PAGADO_Mayo",
  "PAY_AMT6" = "PAGADO_Abril"
)

for (old_name in names(rename_map)) {
  names(clientes)[names(clientes) == old_name] <- rename_map[[old_name]]
}

clientes <- clientes |>
dplyr::mutate(
  SEX = factor(SEX, levels = c(1, 2), labels = c("Hombre", "Mujer")),
  EDUCATION = factor(
    EDUCATION,
    levels = c(1, 2, 3, 4),
    labels = c(
      "Posgrado", "Universidad",
      "Graduado escolar", "Otro"
    )
  ),
  MARRIAGE = factor(
    MARRIAGE,
    levels = c(1, 2, 3),
    labels = c("Casado", "Soltero", "Otro")
  ),
  Pago = factor(
    Pago,
    levels = c(0, 1),
    labels = c("No impago", "Impago")
  ),
  GEedad = cut(
    AGE,
    breaks = c(-Inf, 30, 45, 60, Inf),
    labels = c("Joven", "Adulto joven", "Adulto", "Mayor")
  )
)
```

```

)
)

head(clientes)

## # A tibble: 6 x 26
##       ID LIMIT_BAL SEX      EDUCATION MARRIAGE AGE RETRASOS_Septiembre
##   <dbl>    <dbl> <fct>    <fct>      <fct>    <dbl>          <dbl>
## 1     1      20000 Mujer Universidad Casado      24              2
## 2     2     120000 Mujer Universidad Soltero    26             -1
## 3     3      90000 Mujer Universidad Soltero    34              0
## 4     4      50000 Mujer Universidad Casado     37              0
## 5     5      50000 Hombre Universidad Casado    57             -1
## 6     6      50000 Hombre Posgrado Soltero      37              0
## # i 19 more variables: RETRASOS_Agosto <dbl>, RETRASOS_Julio <dbl>,
## # RETRASOS_Junio <dbl>, RETRASOS_Mayo <dbl>, RETRASOS_Abril <dbl>,
## # DEUDA_Septiembre <dbl>, DEUDA_Agosto <dbl>, DEUDA_Julio <dbl>,
## # DEUDA_Junio <dbl>, DEUDA_Mayo <dbl>, DEUDA_Abril <dbl>,
## # PAGADO_Septiembre <dbl>, PAGADO_Agosto <dbl>, PAGADO_Julio <dbl>,
## # PAGADO_Junio <dbl>, PAGADO_Mayo <dbl>, PAGADO_Abril <dbl>, Pago <fct>,
## # GEdad <fct>

```

Diccionario resumido

Grupo	Variables	Interpretación
Identificación	ID	Identificador único del cliente
Crédito	LIMIT_BAL	Límite concedido en dólares taiwaneses
Perfil	SEX, EDUCATION, MARRIAGE, AGE, GEdad	Características demográficas
Retrasos	RETRASOS_*	Estado de pago durante seis meses
Deuda	DEUDA_*	Importe facturado durante seis meses
Pagos	PAGADO_*	Importe pagado durante seis meses
Objetivo	Pago	Impago o no impago en el periodo siguiente

```

data.frame(
  variable = names(clientes),
  tipo = vapply(clientes, function(x) class(x)[1], character(1)),
  ausentes = vapply(clientes, function(x) sum(is.na(x)), numeric(1))
)

```

```

##           variable      tipo ausentes
## ID              ID numeric          0
## LIMIT_BAL      LIMIT_BAL numeric          0
## SEX             SEX  factor          0
## EDUCATION      EDUCATION factor          0

```



```
## MARRIAGE                MARRIAGE factor      0
## AGE                     AGE numeric        0
## RETRASOS_Septiembre    RETRASOS_Septiembre numeric 0
## RETRASOS_Agosto        RETRASOS_Agosto numeric 0
## RETRASOS_Julio          RETRASOS_Julio numeric 0
## RETRASOS_Junio          RETRASOS_Junio numeric 0
## RETRASOS_Mayo           RETRASOS_Mayo numeric 0
## RETRASOS_Abril          RETRASOS_Abril numeric 0
## DEUDA_Septiembre        DEUDA_Septiembre numeric 0
## DEUDA_Agosto           DEUDA_Agosto numeric 0
## DEUDA_Julio             DEUDA_Julio numeric 0
## DEUDA_Junio             DEUDA_Junio numeric 0
## DEUDA_Mayo              DEUDA_Mayo numeric 0
## DEUDA_Abril             DEUDA_Abril numeric 0
## PAGADO_Septiembre       PAGADO_Septiembre numeric 0
## PAGADO_Agosto          PAGADO_Agosto numeric 0
## PAGADO_Julio            PAGADO_Julio numeric 0
## PAGADO_Junio            PAGADO_Junio numeric 0
## PAGADO_Mayo             PAGADO_Mayo numeric 0
## PAGADO_Abril            PAGADO_Abril numeric 0
## Pago                    Pago factor        0
## GEdad                   GEdad factor       0
```


Análisis exploratorio

Distribución de la variable objetivo

```
prop.table(table(clientes$Pago))
```

```
##
## No impago      Impago
## 0.7768656 0.2231344
```

```
ggplot(clientes, aes(x = Pago, fill = Pago)) +
  geom_bar() +
  scale_fill_manual(values = c("No impago" = "skyblue", "Impago" = "salmon")) +
  labs(
    title = "Distribución de la variable objetivo",
    x = NULL,
    y = "Número de clientes"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```



La clase **No impago** es mayoritaria. Este desequilibrio debe considerarse al interpretar la accuracy: un modelo que siempre predijera la clase mayoritaria podría obtener un porcentaje aparentemente alto sin detectar correctamente los impagos.


Perfil demográfico

```
p_edad <- ggplot(clientes, aes(x = GEdad, fill = Pago)) +  
  geom_bar(position = "fill") +  
  scale_fill_manual(values = c("No impago" = "skyblue", "Impago" = "salmon")) +  
  labs(  
    title = "Proporción de impago por grupo de edad",  
    x = "Grupo de edad",  
    y = "Proporción",  
    fill = "Resultado"  
  ) +  
  theme_minimal()  
  
p_educacion <- ggplot(clientes, aes(x = EDUCATION, fill = Pago)) +
```


```

geom_bar(position = "fill") +
scale_fill_manual(values = c("No impago" = "skyblue", "Impago" = "salmon")) +
labs(
  title = "Proporción de impago por educación",
  x = "Educación",
  y = "Proporción",
  fill = "Resultado"
) +
theme_minimal() +
theme(axis.text.x = element_text(angle = 30, hjust = 1))
p_edad

```



p_educacion



Las variables demográficas muestran diferencias, pero no ofrecen por sí solas una separación fuerte entre clientes con y sin impago. Será necesario incorporar el historial financiero.

```
prop.table(table(clientes$SEX, clientes$Pago), 1)
```

```
##
##           No impago    Impago
##  Hombre 0.7564277 0.2435723
##  Mujer  0.7903108 0.2096892
```

```
prop.table(table(clientes$EDUCATION, clientes$Pago), 1)
```

```
##
##           No impago    Impago
##  Posgrado    0.80757962 0.19242038
##  Universidad 0.76262122 0.23737878
##  Graduado escolar 0.74697312 0.25302688
##  Otro        0.94308943 0.05691057
```

```
prop.table(table(clientes$MARRIAGE, clientes$Pago), 1)
```





```
##
##           No impago    Impago
##  Casado 0.7631520 0.2368480
##  Soltero 0.7893838 0.2106162
##  Otro   0.7358491 0.2641509
```

```
prop.table(table(clientes$GEdad, clientes$Pago), 1)
```

```
##
##           No impago    Impago
##  Joven    0.7739242 0.2260758
##  Adulto joven 0.7897011 0.2102989
##  Adulto    0.7453071 0.2546929
##  Mayor    0.7286245 0.2713755
```

Crédito, deuda y pagos

```
par(mfrow = c(2, 2))
boxplot(clientes$LIMIT_BAL, main = "Límite de crédito", ylab = "NT$")
boxplot(clientes$AGE, main = "Edad", ylab = "Años")
boxplot(
  clientes[, grep("^DEUDA_", names(clientes))],
  main = "Deuda facturada por mes",
  las = 2
)
boxplot(
  clientes[, grep("^PAGADO_", names(clientes))],
  main = "Pagos realizados por mes",
  las = 2
)
```



```
par(mfrow = c(1, 1))
```

Los importes presentan una dispersión elevada. En este contexto los valores extremos no son necesariamente errores: clientes con límites y deudas muy distintos forman parte de la naturaleza del problema. Para evitar

que las variables con mayor escala dominen los algoritmos basados en distancia, se trabajará también con datos estandarizados.


```
orden_meses <- c("Abril", "Mayo", "Junio", "Julio", "Agosto", "Septiembre")

deuda_larga <- clientes |>
  dplyr::select(Pago, dplyr::starts_with("DEUDA_")) |>
  tidyr::pivot_longer(
    cols = -Pago,
    names_to = "Mes",
    values_to = "Importe"
  ) |>
  dplyr::mutate(
    Mes = factor(
      sub("DEUDA_", "", Mes),
      levels = orden_meses
    )
  )

pagos_largos <- clientes |>
  dplyr::select(Pago, dplyr::starts_with("PAGADO_")) |>
  tidyr::pivot_longer(
    cols = -Pago,
    names_to = "Mes",
    values_to = "Importe"
  ) |>
  dplyr::mutate(
    Mes = factor(
      sub("PAGADO_", "", Mes),
      levels = orden_meses
    )
  )

ggplot(deuda_larga, aes(x = Mes, y = Importe, color = Pago, group = Pago)) +
  stat_summary(fun = median, geom = "line", linewidth = 1) +
  stat_summary(fun = median, geom = "point", size = 2.5) +
  scale_color_manual(values = c("No impago" = "skyblue3", "Impago" = "salmon3")) +
  labs(
    title = "Evolución de la deuda mediana",
    x = "Mes",
    y = "Deuda mediana",
    color = "Resultado"
  ) +
  theme_minimal()
```



Evolución de la deuda mediana



```
ggplot(pagos_largos, aes(x = Mes, y = Importe, color = Pago, group = Pago)) +  
  stat_summary(fun = median, geom = "line", linewidth = 1) +  
  stat_summary(fun = median, geom = "point", size = 2.5) +  
  scale_color_manual(values = c("No impago" = "skyblue3", "Impago" = "salmon3")) +
```

```
labs(  
  title = "Evolución del pago mediano",  
  x = "Mes",  
  y = "Pago mediano",  
  color = "Resultado"  
) +  
theme_minimal()
```

Evolución del pago mediano




Correlaciones

```
variables_numericas <- clientes |>
  dplyr::select(
    LIMIT_BAL, AGE,
    dplyr::starts_with("RETRASOS_"),
    dplyr::starts_with("DEUDA_"),
    dplyr::starts_with("PAGADO_")
  )

matriz_cor <- cor(variables_numericas)

corrplot::corrplot(
  matriz_cor,
  method = "color",
  type = "upper",
  tl.cex = 0.65,
  tl.col = "black"
)
```



Los importes de deuda de meses consecutivos están muy correlacionados. También existe relación entre los estados de retraso. Esta redundancia justifica aplicar PCA como herramienta de síntesis.

Reducción de dimensionalidad con PCA

El PCA se aplica a las doce variables continuas de deuda y pagos. Se estandarizan previamente para que todas contribuyan en una escala comparable.

```
variables_cluster <- clientes |>
  dplyr::select(
    dplyr::starts_with("DEUDA_"),
    dplyr::starts_with("PAGADO_")
  )

variables_cluster_scaled <- scale(variables_cluster)

pca_result <- prcomp(
  variables_cluster_scaled,
  center = FALSE,
  scale. = FALSE
)


varianza <- pca_result$sdev^2 / sum(pca_result$sdev^2)
resumen_pca <- data.frame(
  componente = paste0("PC", seq_along(varianza)),
  varianza = round(100 * varianza, 2),
  varianza_acumulada = round(100 * cumsum(varianza), 2)
)

knitr::kable(resumen_pca)
```

componente	varianza	varianza_acumulada
PC1	48.18	48.18
PC2	13.61	61.79
PC3	7.57	69.36
PC4	7.36	76.72
PC5	7.25	83.97
PC6	6.48	90.45
PC7	6.05	96.49
PC8	2.18	98.67
PC9	0.59	99.26
PC10	0.34	99.60
PC11	0.21	99.81
PC12	0.19	100.00


```
factoextra::fviz_eig(
  pca_result,
  addlabels = TRUE,
  ylim = c(0, 55)
)
```

Scree plot



```
factoextra::fviz_pca_var(  
  pca_result,  
  col.var = "contrib",  
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
  repel = TRUE  
)
```

Variables – PCA



```
n_componentes_90 <- which(cumsum(varianza) >= 0.90)[1]
n_componentes_90
```

```
## [1] 6
```

```
componentes_financieros <- as.data.frame(
  pca_result$x[, seq_len(n_componentes_90), drop = FALSE]
)

names(componentes_financieros) <- paste0(
```



```

"PCA_FINANCIERO_",
  seq_len(n_componentes_90)
)

clientes_pca <- dplyr::bind_cols(clientes, componentes_financieros)
head(componentes_financieros)

##   PCA_FINANCIERO_1 PCA_FINANCIERO_2 PCA_FINANCIERO_3 PCA_FINANCIERO_4
## 1      -1.7499268      0.2242172      0.08160684      0.005571944
## 2      -1.6610489      0.1435631      0.05669554     -0.004711140
## 3      -1.1313298      0.1760025     -0.01909098     -0.130004788
## 4      -0.3914071      0.4514650      0.10082996     -0.038163203
## 5      -0.7898197     -0.8617087      0.65536165      0.198484530
## 6      -0.3867589      0.5012428      0.10285155     -0.119239339
##   PCA_FINANCIERO_5 PCA_FINANCIERO_6
## 1      0.04225460     -0.002687842
## 2     -0.04243242      0.026170113
## 3     -0.09687173      0.024080337
## 4      0.05410531     -0.052121940
## 5      0.45068093     -0.323746206
## 6      0.05209756     -0.113040962

```

Las primeras componentes resumen la evolución conjunta de deuda y pagos. El número conservado se determina de forma reproducible mediante el umbral del 90% de varianza acumulada.

Segmentación no supervisada

Los algoritmos basados en distancias se ejecutan sobre una muestra reproducible de 5.000 clientes. Esta decisión mantiene un coste computacional razonable, especialmente en los métodos que necesitan calcular matrices de distancia.

```

set.seed(123)
idx_cluster <- sample(
  seq_len(nrow(variables_cluster)),
  min(nrow(variables_cluster), 5000)
)

cluster_sample <- as.data.frame(variables_cluster[idx_cluster, ])
cluster_sample_scaled <- scale(cluster_sample)


```

Selección del número de clústeres


```

factoextra::fviz_nbclust(
  cluster_sample_scaled,
  kmeans,
  method = "wss",
  k.max = 8,
  nstart = 25
) +
  labs(subtitle = "Método del codo")

```



```
factoextra::fviz_nbclust(  
  cluster_sample_scaled,  
  kmeans,  
  method = "silhouette",  
  k.max = 8,  
  nstart = 25  
) +  
  labs(subtitle = "Método de la silueta")
```



El método del codo, la silueta y la interpretabilidad se consideran de forma conjunta. Se mantiene $k = 3$, ya que permite separar perfiles de deuda baja, intermedia y elevada sin introducir una fragmentación difícil de explicar.

K-means con datos originales y normalizados

```
set.seed(123)
km_original <- kmeans(
  cluster_sample,
  centers = 3,
  nstart = 25
)

set.seed(123)
km_scaled <- kmeans(
```

```

cluster_sample_scaled,
centers = 3,
nstart = 25
)

knitr::kable(
  round(km_original$centers, 2),
  caption = "Centroides con datos originales"
)

```

Table 1: Centroides con datos originales

DEUDA_Sep	DEUDA_Abril	DEUDA_Marzo	DEUDA_Mayo	DEUDA_Junio	DEUDA_Agosto	DEUDA_Octubre	PAGADO_Sep	PAGADO_Abril	PAGADO_Marzo	PAGADO_Mayo	PAGADO_Junio	PAGADO_Agosto	PAGADO_Octubre
21187.23	19330.61	17728.74	16013.49	14895.43	14499.29	3777.37	3829.39	3579.32	3457.36	3503.80	4000.54		
289520.85	289345.32	281781.42	266728.72	249817.62	213873.13	38722.82	23797.81	14889.59	16355.51	19015.95	15388.13		
119112.27	116920.19	113395.97	104427.19	97111.21	92380.07	10057.93	9545.08	8444.66	7431.04	6632.04	8013.32		

```

knitr::kable(
  round(km_scaled$centers, 2),
  caption = "Centroides con datos estandarizados"
)

```

Table 2: Centroides con datos estandarizados


DEUDA_Sep	DEUDA_Abril	DEUDA_Marzo	DEUDA_Mayo	DEUDA_Junio	DEUDA_Agosto	DEUDA_Octubre	PAGADO_Sep	PAGADO_Abril	PAGADO_Marzo	PAGADO_Mayo	PAGADO_Junio	PAGADO_Agosto	PAGADO_Octubre
-0.39	-0.40	-0.41	-0.41	-0.40	-0.39	-0.14	-0.10	-0.12	-0.11	-0.12	-0.10		
3.36	3.48	3.55	3.61	3.56	3.49	1.01	0.87	0.79	0.84	1.10	0.61		
0.95	0.97	1.00	0.97	0.95	0.93	0.37	0.23	0.32	0.28	0.26	0.27		

```

factoextra::fviz_cluster(
  km_scaled,
  data = cluster_sample_scaled,
  geom = "point",
  ellipse.type = "convex",
  ggtheme = theme_minimal(),
  main = "Segmentación k-means con datos estandarizados"
)

```

Segmentación k-means con datos estandarizados



La versión sin normalizar queda dominada por los importes de mayor magnitud. La versión estandarizada ofrece perfiles más equilibrados y será la referencia para las comparaciones posteriores.

K-medians y PAM

K-medians utiliza la mediana como centro y distancia Manhattan. No debe confundirse con PAM, que utiliza observaciones reales como medoides. Para comparar correctamente ambos enfoques se implementan por separado.

```
kmedians <- function(x, centers, nstart = 5, iter.max = 100, tol = 1e-6) {  
  x <- as.matrix(x)  
  best_model <- NULL  
  
  for (start in seq_len(nstart)) {  
    center_matrix <- x[sample(seq_len(nrow(x)), centers), , drop = FALSE]  
  
    for (iteration in seq_len(iter.max)) {  
      distances <- sapply(  
        seq_len(centers),
```

```

    function(j) rowSums(abs(sweep(x, 2, center_matrix[j, ], "-")))
  )

  cluster <- max.col(-distances, ties.method = "random")

  new_centers <- do.call(
    rbind,
    lapply(seq_len(nrow(center_matrix)), function(j) {
      if (sum(cluster == j) == 0) {
        x[sample(seq_len(nrow(x)), 1), ]
      } else {
        apply(x[cluster == j, , drop = FALSE], 2, median)
      }
    })
  )

  if (max(abs(new_centers - center_matrix)) < tol) {
    center_matrix <- new_centers
    break
  }

  center_matrix <- new_centers
}

objective <- sum(abs(x - center_matrix[cluster, , drop = FALSE]))

if (is.null(best_model) || objective < best_model$objective) {
  best_model <- list(
    cluster = cluster,
    centers = center_matrix,
    objective = objective,
    iterations = iteration
  )
}

best_model
}

```

```

set.seed(123)
kmed_model <- kmedians(
  cluster_sample_scaled,
  centers = 3,
  nstart = 5
)

set.seed(123)
pam_model <- cluster::pam(
  cluster_sample_scaled,
  k = 3,
  metric = "manhattan"
)

```

```
## kmedians
##      1      2      3
##  704 2835 1461
```

```
## PAM
##      1      2      3
## 2697 1561  742
```

Table 3: Centros obtenidos con k-medians

DEUDA	SOLICITUD DE FIANZA	DEUDA	DEUDA	DEUDA	MAYOR PAGADO	PAGADO	PAGADO	PAGADO	PAGADO	PAGADO	Abril
1.50	1.50	1.56	1.58	1.59	1.55	0.09	0.06	0.07	0.04	0.05	-0.01
-0.62	-0.62	-0.62	-0.61	-0.60	-0.60	-0.27	-0.19	-0.26	-0.27	-0.27	-0.26
0.01	0.04	0.05	0.07	0.03	0.01	-0.16	-0.13	-0.19	-0.18	-0.18	-0.18

31

```

    mean(cluster::silhouette(pam_model$clustering[sil_idx], dist_sil)[, 3])
  ),
  concordancia_con_kmeans = c(
    1,
    adjusted_rand_index(km_scaled$cluster, kmed_model$cluster),
    adjusted_rand_index(km_scaled$cluster, pam_model$clustering)
  )
)

knitr::kable(
  transform(
    calidad_cluster,
    silueta_media = round(silueta_media, 3),
    concordancia_con_kmeans = round(concordancia_con_kmeans, 3)
  )
)

```

modelo	silueta_media	concordancia_con_kmeans
K-means	0.555	1.000
K-medians	0.308	0.424
PAM	0.288	0.393

K-medians y PAM reducen la influencia de importes extremos. La tabla permite comparar la cohesión interna y la concordancia con la solución de k-means sin depender del número asignado a cada clúster.

Agrupación con distancia Manhattan

```

set.seed(123)
km_manhattan <- amap::Kmeans(
  cluster_sample_scaled,
  centers = 3,
  method = "manhattan",
  iter.max = 100
)

table(
  Kmeans_Euclidea = km_scaled$cluster,
  Kmeans_Manhattan = km_manhattan$cluster
)

```

```

##           Kmeans_Manhattan
## Kmeans_Euclidea    1     2     3
##           1      0 3852     0
##           2      49     1  126
##           3      0  475  497

```

```
adjusted_rand_index(km_scaled$cluster, km_manhattan$cluster)
```

```
## [1] 0.601798
```


La distancia Manhattan es menos sensible a diferencias extremas en una sola variable. La comparación permite comprobar si los perfiles se mantienen al cambiar la geometría utilizada por el algoritmo.

DBSCAN y OPTICS


Los métodos basados en densidad se prueban con distintos valores de `eps`. Para reducir el coste de la matriz de distancias se utiliza una muestra de 3.000 observaciones.

```
set.seed(123)
idx_density <- sample(
  seq_len(nrow(cluster_sample_scaled)),
  min(3000, nrow(cluster_sample_scaled))
)

density_sample <- cluster_sample_scaled[idx_density, ]
min_pts <- 2 * ncol(density_sample)
kdlist <- dbscan::kNNdist(density_sample, k = min_pts)
eps_candidates <- as.numeric(quantile(kdlist, c(0.75, 0.85, 0.95)))

plot(
  sort(kdlist),
  type = "l",
  main = "Distancia al vecino k para seleccionar eps",
  xlab = "Observaciones ordenadas",
  ylab = paste0("Distancia al vecino ", min_pts)
)
abline(h = eps_candidates, col = c("steelblue", "orange", "red"), lty = 2)
```

Distancia al vecino k para seleccionar eps



```
dbscan_models <- lapply(  
  eps_candidates,  
  function(eps_value) {  
    dbscan::dbscan(  
      density_sample,  
      eps = eps_value,  
      minPts = min_pts  
    )  
  }  
)  
  
dbscan_summary <- data.frame(  
  eps = round(eps_candidates, 3),  
  clusters = vapply(  
    dbscan_models,  
    function(model) length(setdiff(unique(model$cluster), 0)),  
    numeric(1)  
  ),  
  porcentaje_ruido = round(  
    100 * vapply(  
      dbscan_models,  
      function(model) length(setdiff(unique(model$cluster), 0)),  
      numeric(1)  
    ),  
    1  
  )  
)
```

```

    dbscan_models,
    function(model) mean(model$cluster == 0),
    numeric(1)
  ),
  2
)
)

knitr::kable(dbscan_summary)

```

eps	clusters	porcentaje_ruido
0.857	1	17.97
1.385	1	10.73
3.393	1	2.90


```

optics_model <- dbscan::optics(
  density_sample,
  minPts = min_pts
)

plot(optics_model, main = "Reachability plot de OPTICS")

```

Reachability plot de OPTICS



```
optics_clusters <- dbscan::extractDBSCAN(  
  optics_model,  
  eps_cl = eps_candidates[2]  
)
```

```
table(optics_clusters$cluster)
```


```
##  
##      0      1  
## 322 2678
```

```
pca_density <- prcomp(density_sample)$x[, 1:2] |>  
  as.data.frame()
```

```
pca_density$DBSCAN <- factor(dbscan_models[[2]]$cluster)  
pca_density$OPTICS <- factor(optics_clusters$cluster)
```


```
ggplot(pca_density, aes(x = PC1, y = PC2, color = DBSCAN)) +  
  geom_point(alpha = 0.55, size = 1.2) +
```

```
labs(title = "DBSCAN proyectado sobre las dos primeras componentes") +  
theme_minimal()
```



```
ggplot(pca_density, aes(x = PC1, y = PC2, color = OPTICS)) +  
geom_point(alpha = 0.55, size = 1.2) +  
labs(title = "OPTICS proyectado sobre las dos primeras componentes") +  
theme_minimal()
```

OPTICS proyectado sobre las dos primeras componentes



Si la mayor parte de las observaciones se concentra en un único grupo o se clasifica como ruido, la estructura del dataset no está bien representada por regiones de densidad separadas. En ese caso k-means, k-medians o PAM ofrecen una segmentación más estable e interpretable.

Modelos supervisados

Preparación de entrenamiento y test

Se utiliza una división estratificada del 70% para entrenamiento y 30% para test. El muestreo estratificado mantiene la proporción de impagos en ambos conjuntos.

```
datos_modelo <- clientes |>
  dplyr::select(-ID, -GEdad)

set.seed(123)
train_index <- caret::createDataPartition(
  datos_modelo$Pago,
  p = 0.70,
```

```

    list = FALSE
  )

train_data <- datos_modelo[train_index, ]
test_data <- datos_modelo[-train_index, ]

data.frame(
  conjunto = c("Entrenamiento", "Test"),
  observaciones = c(nrow(train_data), nrow(test_data)),
  porcentaje_impago = round(
    100 * c(
      mean(train_data$Pago == "Impago"),
      mean(test_data$Pago == "Impago")
    ),
    2
  )
)

##           conjunto observaciones porcentaje_impago
## 1 Entrenamiento      20722          22.31
## 2           Test       8879          22.31

```

Árbol de decisión sin poda y podado

```

set.seed(123)
arbol_completo <- rpart::rpart(
  Pago ~ .,
  data = train_data,
  method = "class",
  control = rpart::rpart.control(
    cp = 0,
    minsplit = 50,
    maxdepth = 12,
    xval = 10
  )
)

cp_optimo <- arbol_completo$cptable[
  which.min(arbol_completo$cptable[, "xerror"]),
  "CP"
]

arbol_podado <- prune(
  arbol_completo,
  cp = cp_optimo
)


cp_optimo

## [1] 0.002595156

```

```
rpart.plot::rpart.plot(  
  arbol_completo,  
  type = 2,  
  extra = 104,  
  fallen.leaves = TRUE,  
  main = "Árbol sin poda"  
)
```



Árbol sin poda



```
rpart.plot::rpart.plot(
  arbol_podado,
  type = 2,
  extra = 104,
```

```
fallen.leaves = TRUE,  
main = "Árbol podado"  
)
```

Árbol podado



```

pred_arbol_completo <- predict(
  arbol_completo,
  test_data,
  type = "class"
)

pred_arbol_podado <- predict(
  arbol_podado,
  test_data,
  type = "class"
)

cm_arbol_completo <- caret::confusionMatrix(
  pred_arbol_completo,
  test_data$Pago,
  positive = "Impago"
)

cm_arbol_podado <- caret::confusionMatrix(
  pred_arbol_podado,
  test_data$Pago,
  positive = "Impago"
)

cm_arbol_completo

```

```

## Confusion Matrix and Statistics
##
##           Reference
## Prediction No impago Impago
##   No impago      6388   1256
##   Impago         510    725
##
##           Accuracy : 0.8011
##           95% CI : (0.7926, 0.8094)
##   No Information Rate : 0.7769
##   P-Value [Acc > NIR] : 0.00000001515
##
##           Kappa : 0.3373
##
##   McNemar's Test P-Value : < 0.00000000000000022
##
##           Sensitivity : 0.36598
##           Specificity : 0.92607
##           Pos Pred Value : 0.58704
##           Neg Pred Value : 0.83569
##           Prevalence : 0.22311
##           Detection Rate : 0.08165
##   Detection Prevalence : 0.13909
##           Balanced Accuracy : 0.64602
##
##           'Positive' Class : Impago
##

```

```
cm_arbol_podado
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  No impago Impago
##   No impago      6620   1306
##   Impago         278    675
##
##           Accuracy : 0.8216
##           95% CI : (0.8135, 0.8295)
##   No Information Rate : 0.7769
##   P-Value [Acc > NIR] : < 0.00000000000000022
##
##           Kappa : 0.3686
##
## Mcnemar's Test P-Value : < 0.00000000000000022
##
##           Sensitivity : 0.34074
##           Specificity : 0.95970
##           Pos Pred Value : 0.70829
##           Neg Pred Value : 0.83523
##           Prevalence : 0.22311
##           Detection Rate : 0.07602
##   Detection Prevalence : 0.10733
##           Balanced Accuracy : 0.65022
##
##           'Positive' Class : Impago
##
```

La poda reduce la complejidad y facilita la interpretación. La comparación no debe basarse únicamente en accuracy: sensibilidad, especificidad, balanced accuracy y Kappa permiten comprobar si el modelo identifica la clase de impago.

Random Forest con muestreo balanceado

Random Forest permite capturar relaciones no lineales y combinaciones entre variables. Para evitar que cada árbol se concentre en la clase mayoritaria, se equilibra el bootstrap interno mediante `samplesize`.

```
class_counts <- table(train_data$Pago)
balanced_size <- min(class_counts)

set.seed(123)
rf_balanced <- randomForest::randomForest(
  Pago ~ .,
  data = train_data,
  ntree = 300,
  mtry = floor(sqrt(ncol(train_data) - 1)),
  importance = TRUE,
  samplesize = rep(balanced_size, length(class_counts))
)

rf_balanced
```

```
##
## Call:
## randomForest(formula = Pago ~ ., data = train_data, ntree = 300,      mtry = floor(sqrt(ncol(train_
##           Type of random forest: classification
##           Number of trees: 300
## No. of variables tried at each split: 4
##
##           OOB estimate of  error rate: 21.75%
## Confusion matrix:
##           No impago Impago class.error
## No impago      13557    2541    0.1578457
## Impago         1966    2658    0.4251730
```

```
pred_rf <- predict(
  rf_balanced,
  test_data,
  type = "class"
)

cm_rf <- caret::confusionMatrix(
  pred_rf,
  test_data$Pago,
  positive = "Impago"
)


cm_rf
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction No impago Impago
## No impago      5793    822
## Impago         1105   1159
##
##           Accuracy : 0.783
##           95% CI : (0.7742, 0.7915)
## No Information Rate : 0.7769
## P-Value [Acc > NIR] : 0.086
##
##           Kappa : 0.4043
##
## Mcnemar's Test P-Value : 0.0000000001327
##
##           Sensitivity : 0.5851
##           Specificity : 0.8398
##           Pos Pred Value : 0.5119
##           Neg Pred Value : 0.8757
##           Prevalence : 0.2231
##           Detection Rate : 0.1305
##           Detection Prevalence : 0.2550
##           Balanced Accuracy : 0.7124
##
##           'Positive' Class : Impago
##
```

```
randomForest::varImpPlot(
  rf_balanced,
  type = 2,
  main = "Importancia de variables en Random Forest"
)
```

Importancia de variables en Random Forest

RETRASOS_Septiembre
 DEUDA_Septiembre
 LIMIT_BAL
 PAGADO_Septiembre
 DEUDA_Agosto
 AGE
 PAGADO_Agosto
 DEUDA_Julio
 DEUDA_Junio
 DEUDA_Mayo
 DEUDA_Abril
 PAGADO_Abril
 PAGADO_Julio
 PAGADO_Junio
 PAGADO_Mayo
 RETRASOS_Agosto
 RETRASOS_Julio
 RETRASOS_Junio
 RETRASOS_Mayo
 EDUCATION
 RETRASOS_Abril
 MARRIAGE
 SEX



Comparación de modelos

```
extract_metrics <- function(cm) {
  c(
    Accuracy = unname(cm$overall["Accuracy"]),
    Kappa = unname(cm$overall["Kappa"]),
    Sensibilidad = unname(cm$byClass["Sensitivity"]),
    Especificidad = unname(cm$byClass["Specificity"]),
    Balanced_Accuracy = unname(cm$byClass["Balanced Accuracy"])
  )
}
```

```

}

comparacion_modelos <- rbind(
  "Árbol sin poda" = extract_metrics(cm_arbol_completo),
  "Árbol podado" = extract_metrics(cm_arbol_podado),
  "Random Forest balanceado" = extract_metrics(cm_rf)
)

knitr::kable(
  round(comparacion_modelos, 3),
  caption = "Rendimiento sobre el conjunto de test"
)

```

Table 4: Rendimiento sobre el conjunto de test

	Accuracy	Kappa	Sensibilidad	Especificidad	Balanced_Accuracy
Árbol sin poda	0.801	0.337	0.366	0.926	0.646
Árbol podado	0.822	0.369	0.341	0.960	0.650
Random Forest balanceado	0.783	0.404	0.585	0.840	0.712

El modelo preferido debe mantener un equilibrio razonable entre detección de impagos y clasificación de clientes sin impago. En un problema de riesgo crediticio, un falso negativo puede ser más costoso que un falso positivo, por lo que la sensibilidad de la clase **Impago** tiene especial relevancia.

Limitaciones y riesgos de uso

El dataset presenta varias limitaciones que condicionan los resultados:

- **Antigüedad y contexto:** los datos corresponden a Taiwán y a un periodo concreto. El comportamiento financiero, la regulación y las condiciones económicas pueden haber cambiado.
- **Variables disponibles:** no se incluyen ingresos, estabilidad laboral, patrimonio, tipo de contrato, movimientos recientes o información macroeconómica.
- **Desbalanceo:** la clase de impago es minoritaria. La accuracy por sí sola puede ofrecer una imagen demasiado optimista.
- **Correlación temporal:** deuda, retrasos y pagos mensuales contienen información redundante. Esto afecta a la interpretación y justifica el uso de PCA.
- **Valores extremos:** los importes tienen una dispersión alta. Aunque muchos son legítimos, influyen en algoritmos basados en medias y distancias.
- **Riesgo de discriminación:** sexo, edad, educación y estado civil son variables sensibles. Un uso real exigiría revisión legal, evaluación de sesgos y mecanismos de explicación y reclamación.
- **Cambio de distribución:** un modelo entrenado con datos históricos puede degradarse si cambian los perfiles de cliente o las políticas de crédito.

El resultado no debe utilizarse como una decisión automática de concesión. Su uso razonable sería como señal adicional dentro de un proceso revisado por especialistas, con monitorización periódica y validación sobre datos actuales.

Conclusiones

El análisis muestra que el comportamiento financiero mensual contiene más información que las variables demográficas por separado. Las deudas y pagos están fuertemente correlacionados, y PCA permite resumir parte de esa redundancia.

En la segmentación, la estandarización es imprescindible. K-means ofrece una separación sencilla de interpretar, mientras que k-medians y PAM aportan mayor robustez frente a importes extremos. DBSCAN y OPTICS dependen de forma intensa de sus parámetros y pueden no encontrar grupos diferenciados cuando las observaciones se solapan en alta dimensión.

En la clasificación, el árbol podado facilita la explicación de las reglas y Random Forest aporta mayor flexibilidad. La comparación final debe priorizar la sensibilidad y la balanced accuracy, no solo el porcentaje global de aciertos.

Como siguiente paso de un proyecto real sería necesario entrenar con información más reciente, ajustar costes distintos para falsos positivos y falsos negativos, estudiar calibración de probabilidades y evaluar equidad entre grupos antes de plantear una aplicación operativa.

Referencias

- UCI Machine Learning Repository. *Default of Credit Card Clients*: <https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>
- Yeh, I. C. y Lien, C. H. (2009). *The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients*. Expert Systems with Applications, 36(2), 2473-2480.
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.

Información de la sesión

```
sessionInfo()
```

```
## R version 4.5.1 (2025-06-13 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=Spanish_Spain.utf8  LC_CTYPE=Spanish_Spain.utf8
## [3] LC_MONETARY=Spanish_Spain.utf8 LC_NUMERIC=C
## [5] LC_TIME=Spanish_Spain.utf8
##
## time zone: Europe/Madrid
## tzcode source: internal
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  methods   base
##
## other attached packages:
## [1] amap_0.8-20      randomForest_4.7-1.2 rpart.plot_3.1.3
```



```

## [4] rpart_4.1.24          caret_7.0-1          lattice_0.22-7
## [7] dbscan_1.2.3          cluster_2.1.8.1      corrplot_0.95
## [10] factoextra_1.0.7      ggplot2_4.0.3        tidyr_1.3.1
## [13] dplyr_1.2.1           readxl_1.4.5
##
## loaded via a namespace (and not attached):
## [1] tidyselect_1.2.1      timeDate_4051.111    farver_2.1.2
## [4] S7_0.2.0             fastmap_1.2.0        pROC_1.19.0.1
## [7] digest_0.6.37        timechange_0.3.0     lifecycle_1.0.5
## [10] survival_3.8-3       magrittr_2.0.4       compiler_4.5.1
## [13] rlang_1.2.0          tools_4.5.1          utf8_1.2.6
## [16] yaml_2.3.10          data.table_1.17.8    ggsignif_0.6.4
## [19] knitr_1.51           labeling_0.4.3        plyr_1.8.9
## [22] RColorBrewer_1.1-3   abind_1.4-8          withr_3.0.2
## [25] purrr_1.1.0          nnet_7.3-20          grid_4.5.1
## [28] stats4_4.5.1         ggpubr_0.6.1         e1071_1.7-16
## [31] future_1.69.0        globals_0.18.0       scales_1.4.0
## [34] iterators_1.0.14     MASS_7.3-65          tinytex_0.57
## [37] cli_3.6.5            rmarkdown_2.31       generics_0.1.4
## [40] rstudioapi_0.17.1    future.apply_1.20.0  reshape2_1.4.4
## [43] proxy_0.4-27         stringr_1.5.2        splines_4.5.1
## [46] parallel_4.5.1       cellranger_1.1.0     vctrs_0.7.3
## [49] hardhat_1.4.2        Matrix_1.7-3         carData_3.0-5
## [52] car_3.1-3            rstatix_0.7.2        ggrepel_0.9.6
## [55] Formula_1.2-5        listenv_0.10.0       foreach_1.5.2
## [58] gower_1.0.2          recipes_1.3.1        glue_1.8.0
## [61] parallelly_1.45.1    codetools_0.2-20     lubridate_1.9.4
## [64] stringi_1.8.7        gtable_0.3.6         tibble_3.3.0
## [67] pillar_1.11.1        htmltools_0.5.8.1    ipred_0.9-15
## [70] lava_1.8.2           R6_2.6.1             evaluate_1.0.5
## [73] backports_1.5.0      broom_1.0.10         class_7.3-23
## [76] Rcpp_1.1.0           nlme_3.1-168         proclim_2025.04.28
## [79] xfun_0.53            pkgconfig_2.0.3      ModelMetrics_1.2.2.2

```